UM ESTUDO COMPARATIVO ENTRE MODELOS DE CONCORRÊNCIA COM ÊNFASE EM ESCALABILIDADE PARA APLICAÇÕES WEB

Mauricio Colognese Concatto

Orientador: Prof. Pablo Dall'Oglio

Roteiro

- Introdução
 - Motivação
 - Objetivos
 - Metodologia
- Conceitos importantes
 - Processos
 - Threads
 - Context switch
 - Entrada/Saída (E/S)

- Trabalho Proposto
 - Cenários
 - Métricas
 - Modelos de concorrência
 - Arquitetura
 - Testes
- Resultados
- Considerações finais

Introdução

- Web 2.0
 - Aplicações Web mais acessíveis, dinâmicas e interativas
 - Aplicações mais focadas em problemas específicos
 - APIs para integração
- Ascenção da computação em nuvem: IaaS, PaaS, SaaS...
- "The Free Lunch Is Over". Herb Sutter (2005).
 - Clock das CPUs chegando ao limite
 - Necessidade de explorar os novos recursos disponíveis nos hardwares e softwares atuais
 - Escalabilidade através da concorrência

Motivação

- Desafios de aplicações Web operando no modelo SaaS
 - Alta variação de carga e acessos concorrentes
- Diferentes modelos para a implementação de servidores
 - Thread-per-connection (multithread): Apache, Tomcat (Servlets)
 - Event-driven: Nginx, NodeJS
- Comparativos existentes entre os modelos abordam o problema de maneira superficial
- Que benefícios podem ser obtidos ao aplicar estes conceitos em toda a arquitetura de uma aplicação?
- Todos os tipos de aplicações podem se beneficiar ?

Objetivos

- Realizar um estudo comparativo detalhado sobre o modelo multithread e o modelo de atores em aplicações Web
- Preencher as lacunas existentes nos diversos estudos encontrados sobre o assunto
- Objetivos específicos:
 - Revisão bibliográfica sobre tema
 - Definir um conjunto de cenários sobre os quais serão feitas as avaliações
 - Implementar protótipos dos cenários definidos em ambos os modelos selecionados
 - Realizar simulações de carga nos protótipos desenvolvidos
 - Coletar os dados resultantes das simulações
 - Analisar quantitativamente os dados coletados

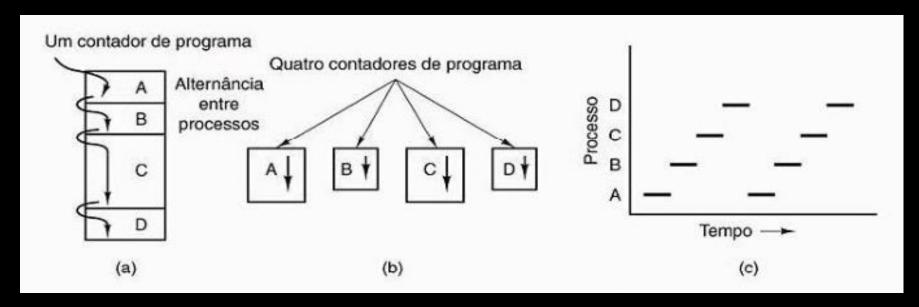
Metodologia

- Pesquisa exploratória
 - Aproximação com o tema
- Pesquisa bibliográfica
 - Revisão da literatura existente sobre os assuntos que compõem o estudo
- Pesquisa quantitativa
 - Comparação de dados obtidos através dos experimentos realizados
- Pesquisa de laboratório
 - Uso de ambientes controlados para execução de testes e obtenção de dados

Conceitos Importantes

Processos

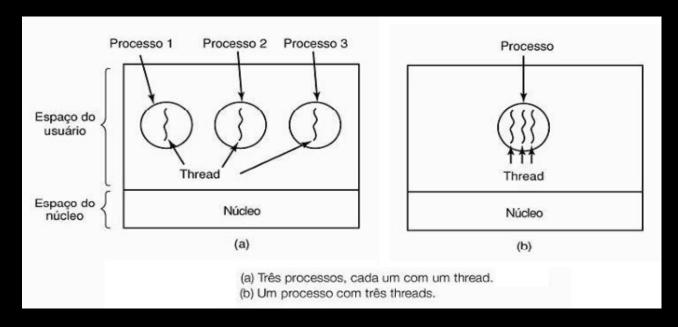
- Abstração de um programa em execução
 - Isolamento
 - Área de memória dedicada
- Comunicação: Uso de mecanismos de Inter-process Communication (IPC)
- Sistema Operacional: Uso de algoritmos de escalonamento para definir quando parar um processo e iniciar outro



Fonte: (TANENBAUM, 2010)

Threads

- Fluxos de execução que residem e compartilham recursos já alocados por um processo
- Menor custo de alocação
- Memória compartilhada
- Uso de técnicas de sincronização



Fonte: (TANENBAUM, 2010)

Context switch

- Alternar entre a execução de processos ou *threads* obriga o sistema operacional a salvar e restaurar o contexto de execução
- Custo: ~1.000-3.000ns
 - Arquiteturas Sandy Bridge
 - Família Intel 2xxx
 - 17 2600K, 15 2500K, etc.
 - Kernel Linux 2.6+
- Afeta a execução dos programas
 - Processador
 - Invalidação de cache (TLB)
 - Invalidação do *pipeline* de execução

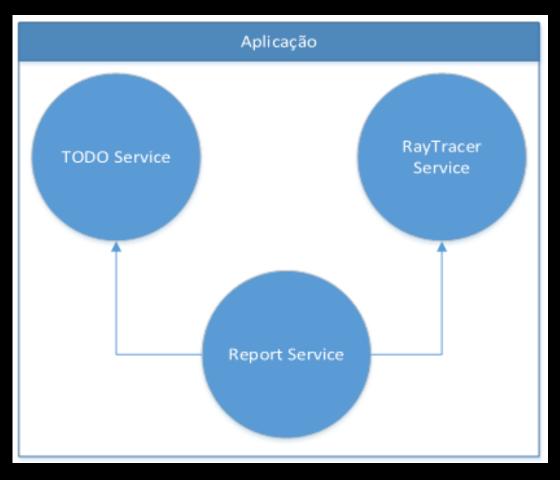
Entrada/Saída (E/S)

- Operações envolvendo leitura e escrita em descritores
- Extremamente lentas (em comparação ao processador)
- E/S Síncrona
 - Thread/Processo fica bloqueado até toda operação de E/S ser finalizada
- E/S Assíncrona
 - Dispara a execução e retorna o controle imediatamente
 - Coordenado por operações de callback invocadas pelo SO quando o descritor esta pronto para leitura/escrita

Trabalho proposto

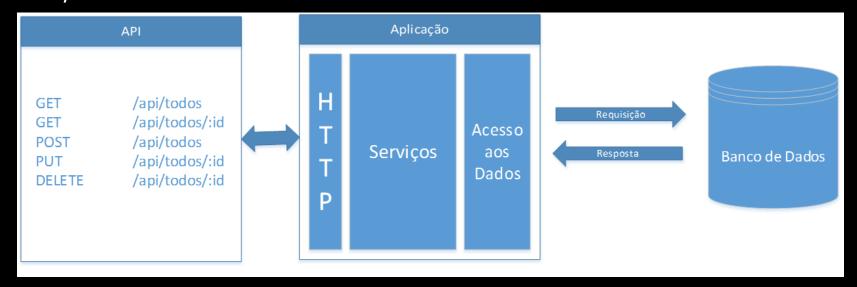
- Cenários
- Métricas
- Modelos de concorrência
- Arquitetura
- Testes

Cenários



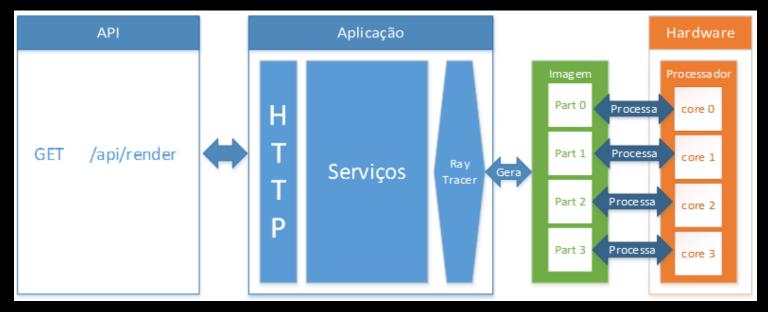
TODO service

- Objetivo: Gerenciamento de uma lista de tarefas
- Características
 - Utilização de um banco de dados (PostgreSQL)
 - Expõem API via HTTP
 - Carga de trabalho mista
 - Processamento
 - E/S



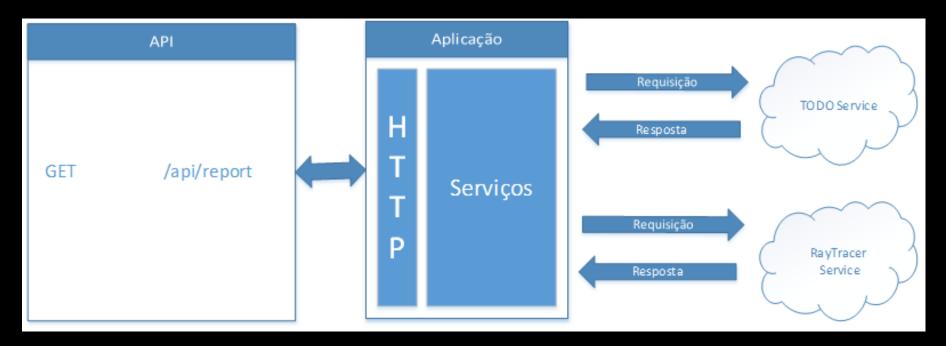
Raytracer service

- Objetivo: Geração imagens utilizando o método de renderização Ray tracing
- Características
 - Expõem API via HTTP
 - Busca simular aplicações que fazem uso intenso do processador e devido a isso são altamente bloqueantes



Report service

- Objetivo: Geração de relatório HTML baseado no resultado coletado das outras duas aplicações
- Características
 - Expõem API via HTTP
 - Busca simular aplicações que possuam alta dependência de operações de E/S.

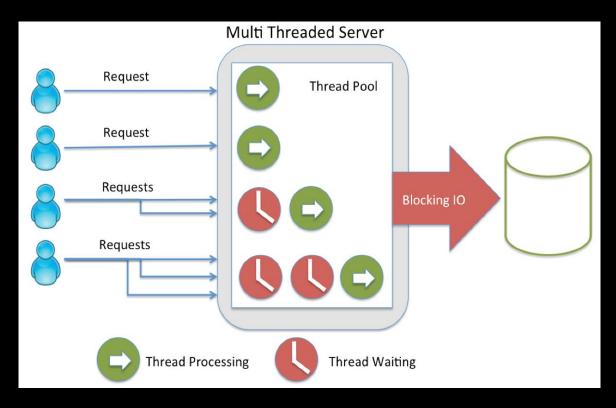


Métricas

- Métricas coletadas durante a execução das simulações de carga:
 - Tempo de resposta mínimo, médio e máximo
 - Uso do processador pela aplicação
 - Memória utilizada pela aplicação
 - Número de threads alocadas durante a simulação

Modelo Multithread

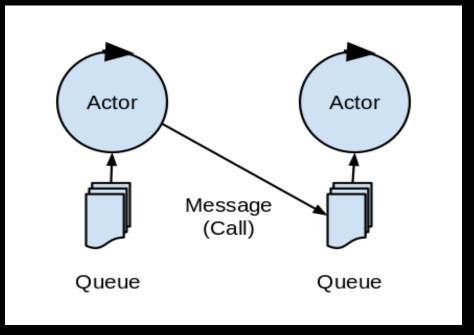
- Threads
- Memória compartilhada
- Estruturas de sincronização
 - Locks



Fonte: Retirado da página Strongloop

Modelo de atores

- Foco na troca de mensagens
- Canais de comunicação assíncronos
- Atores
 - Mensagens imutáveis
 - Encapsulamento do estado
 - Uso de filas (caixa de mensagens)
 - Evitar processamento bloqueante

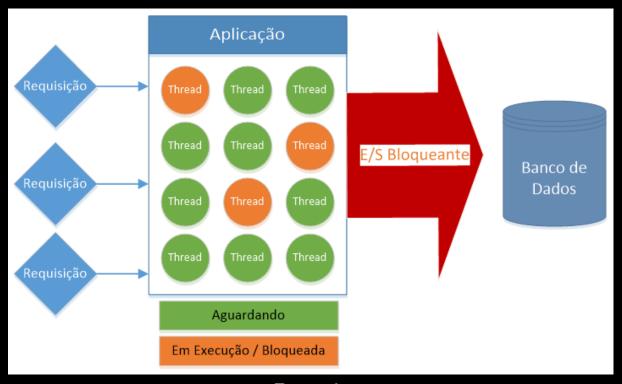


Fonte: Retirado da página Java is the new C

Arquitetura

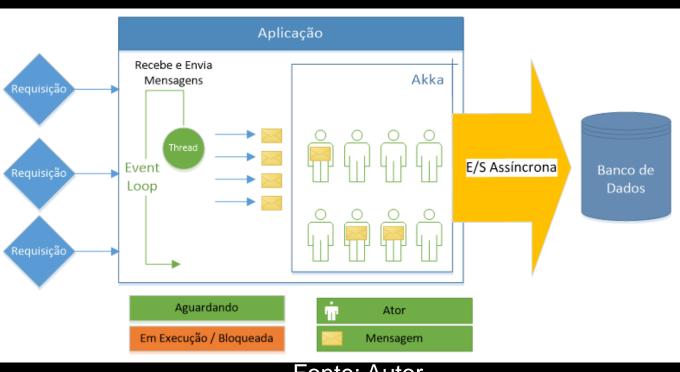
Modelo Multithread

- Thread-per-connection
- HTTP: Spring MVC (Tomcat Servlet)
- Acesso a banco de dados: Spring JDBC (JDBC)
- Uso de E/S síncrona



Modelo de Atores

- Akka
- HTTP: Akka HTTP
- Acesso a banco de dados: Postgres Async Driver
- Uso de E/S assíncrona



Testes

Ambiente

- 4 VMs tipo n1-highcpu-2 Google Cloud
 - Processador: Intel Xeon E5-2697v3 2,30GHz (dois núcleos)
 - Memória: 1,8GB 1600MHz
 - Disco: SSD 10GB sem especificação
 - Sistema Operacional: Ubuntu Server 16.04
- Uma VM por serviço:
 - PostgreSQL
 - TODO Service
 - RayTracer Service
 - Report Service
- Estabelecido limite de 1GB de memória para as aplicações na JVM

Condução dos testes

- Inicialização da aplicação e de suas dependências através de *scripts* (realizam limpeza do ambiente como por exemplo banco de dados, arquivos temporários, etc.)
- Inicialização do VisualVM e conexão com a aplicação para realização do monitoramento
- Realização das três execuções da simulação utilizando o Gatling
- Coleta dos resultados

Carga de teste

Aplicação	Usuários Simulados	Requisições Por Usuário	Total de Requisições
TODO service	1.000	5	5.000
Raytracer service	50	1	50
Report service	50	1	50

Resultados

TODO Service

Critério	Multithread	Atores
Tempo total (s)	166	6
Tempo médio resposta (s)	19,63	0,5
Throughput (Req./s)	30,12	833,33
Req. com erros (%)	11,38	0
Uso CPU (%)	~20-50	~90
Uso Memória (MB)	~350-500	~80-125
Threads	~50-223	~20-27

TODO Service

- Multithread
 - Alto uso de memória
 - Esgotamento do thread pool do Tomcat (max. 200)
 - Alto numero de *threads* alocadas
 - Processador ocioso (aguardando E/S)
 - Context Switch
 - Maior atividade do Garbage Collector

- Atores
 - Baixo consumo de memória:
 - Uso de poucas *threads*
 - E/S assíncrona
 - Uso mais eficiente do processador
 - Menos threads = menos operações de context switch = execução continua

Raytracer Service

Critério	Multithread	Atores
Tempo total (s)	61	21
Tempo médio resposta (s)	60	18,1
Throughput (Req./s)	0,82	2,38
Req. com erros (%)	100	76
Uso CPU (%)	~100	~100
Uso Memória (MB)	~100-300	~100-300
Threads	~70-120	~16-25

Raytracer Service

- Consumo de recursos similar
- Multithread
 - 50 requisições competindo pelo processador (2 núcleos)
 - Context switch
- Atores
 - 2 execuções simultâneas (2 núcleos)
 - Uso de filas
 - Enfileiramento da execução permitiu um uso mais eficiente do processador
 - Menos operações de Context switch

Report Service

Critério	Multithread	Atores
Tempo total (s)	61	21
Tempo médio resposta (s)	60	17,4
Throughput (Req./s)	0,82	2,38
Req. com erros (%)	100	76
Uso CPU (%)	~0-10	~0-10
Uso Memória (MB)	~100-250	~20-80
Threads	~30-72	~16-24

Report Service

- Replicação do resultado o microservice mais lento (RayTracer Service)
- Modo como o teste foi arquitetado impede uma comparação de performance entre as implementações
- Uso de recursos
 - Modelo de atores consegue trabalhar de maneira mais eficiente e com um menor consumo de memória devido ao baixo número de threads alocadas
 - Uso de E/S assíncrona

Conclusão

- O estudo conseguiu complementar a lacuna de informação encontrada em diversos comparativos existentes na Web
- O estudo gerou resultados relevantes:
 - A pesquisa permitiu identificar o potencial do modelo de atores em conjunto com operações de E/S assíncronas para a criação de aplicações de alta performance
 - As implementações e testes realizados permitiram comprovar na prática este potencial
- Foi possível atingir os objetivos estabelecidos no início do trabalho.

Dúvidas?